


# MLR: 海量数据下的非线性模型探索

靖世(盖坤)





# 个人简介

- 花名：靖世      姓名：盖坤
- 学校：清华大学 博士
- 研究方向: 机器学习 论文情况: NIPS,TPAMI ,AAAI,CVPR等
- 所属部门：阿里妈妈事业部-广告算法-基础研究
- 主要研究方向：
  - 机器学习算法创新
  - 广告算法应用研究(Rank Model)



## ● 提纲

- 1. 线性的限制和分片线性模型MLR
- 2. 模型对比和应用效果
- 3. MLR和topic model的关系
- 4. MLR for click model:偏移变量分解
- 5. 迁移不同场景数据：Transfer MLR



# 分片线性模型

- 互联网行业机器学习算法的问题：


- 大规模、高维度数据
- 已有非线性学习算法复杂度高
- 广泛使用线性模型，无法利用数据中非线性规律
  - 人工预处理，难度大，难以最优

ad\_ctr, cate\_ctr, ad\_pv 为特征，  
线性模型无法拟合如下规则：


$$y = \begin{cases} ad\_ctr, & \text{if } ad\_pv > K; \\ cate\_ctr, & \text{if } ad\_pv \leq K. \end{cases}$$

- 挑战：如何从大规模高维度数据中学习**非线性**模型？
- 我们的工作：**发明新的分片线性学习算法—Mixture of Logistic Regression**


例子：分类问题



训练数据



线性模型(LR)



分片线性模型



# MLR: 模型形式

作用范围

基预测器

- 分而治之  $f(x) = g\left(\sum_i \pi_i(x, \mu) \eta_i(x, w)\right)$

- 空间划分为多个局部区域，每个区域内一个线性预测模型

逻辑回归:  $p(y = 1|x) = \frac{1}{1 + \exp(-wx)}$

## – 分类问题：

- 分片线性分类:  $p(y = 1|x) = \frac{1}{1 + \exp\left(-\sum_i \pi_i(x)(w_i x)\right)}$

- 混合逻辑回归:

$$p(y = 1|x) = \sum_{j=1}^m \frac{e^{\mu_j \cdot x}}{\sum_{v=1}^m e^{\mu_v \cdot x}} \cdot \frac{1}{1 + e^{-w_j \cdot x}}$$

以此为例

## – 回归问题：

$$y(x) = \sum_{j=1}^m \pi_i(x) \cdot (w_i x)$$

## – 目标函数：

似然、误差平方和、Bregman散度等

- 模型不限定为隐变量概率模型，算法引入分组稀疏，适用于大规模高维度数据



# MLR:正则化和目标函数

- MLR:

$$f(x; \theta) = \sum_{j=1}^m \frac{e^{\mu_j \cdot x}}{\sum_{v=1}^m e^{\mu_v \cdot x}} \cdot \frac{1}{1 + e^{-w_j \cdot x}}$$

- 参数矩阵:

$$\theta = [w_1, \dots, w_m, \mu_1, \dots, \mu_m]$$

- 特征选择：同一维度对应多个权重 — 分组稀疏正则

$$\|\theta\|_{2,1} = \sum_i \sqrt{\sum_k \theta_{ik}^2}$$

- 目标函数:

$$\min_{\theta} F(\theta) = \sum_i l(f(x_i; \theta), y_i) + \lambda \|\theta\|_{2,1} + \beta \|\theta\|_1$$



# MLR: 算法设计

- 目标函数:  $\min_{\theta} f(\theta) = \sum_i l(f(x_i; \theta), y_i) + \lambda \|\theta\|_{2,1} + \beta \|\theta\|_1$
- 难度和挑战：
  - 目标函数非凸，非光滑（不可导，不存在次梯度）
  - 提出针对**非凸非光滑目标的快速优化方法**
    - 思路：证明存在方向导数，最速下降方向唯一，找出最速下降方向，加速为superlinear下降。
  - 算法实现：
    - 部署于200台MPI计算节点，目前支持约20T训练数据，千亿级别样本的训练(受限于集群总内存，支持规模随机器数增大)



# MLR: 特性

- 特点
  - 分而治之
  - 可以适用于大规模高维度数据
  - 模型复杂度可控：可以线性，也可以逼近任意复杂非线性函数
  - 具有自动特征选择作用
  - 模型结构符合广告数据规律





# MLR:模型对比

- MLR vs. LR

- 例子: 推荐宝贝ranking数据

测试AUC	预估ctr	预估pcvr
LR	0.700112	0.748859
MLR(m=51)	<b>0.713173</b>	<b>0.775776</b>
提升值(百分点绝对值)	<b>+1.3061</b>	<b>+2.6917</b>

- MLR vs. GBDT(boosting)

- 例子: 2012年上半年站内定向广告ranking数据

AUC	GBDT (tree:800,depth:6)	MLR (m=50)	MLR (m=150,未收敛 模型)	MLR(150, 收敛模 型)
训练集 (前一天)	0.664416	0.660369	0.664559	0.666423
测试集 (后一天)	0.661497	0.665067	0.665884	0.667163

- 此外,GBDT不适合超高维度数据



# MLR: 应用效果

- 定向广告质量分6期、7期
  - 试验田CTR/RPM ↑ 30+%
  - 生产 CTR ↑ 20+%, RPM ↑ 10+%
- 转化率预估
  - 6-9月:淘客宝贝搜索ctr ↑ 5+%, pcvr ↑ 3-7%
  - 10-11月:覆盖流量上CTR ↑ 35%,PCVR ↑ 30%,RPM ↑ 25%
  - 正在上线:实验流量上PCVR ↑ 20+%
- 个性化推荐融合排序
  - CTR ↑ 8%,PCVR ↑ 11%
- 其它:
  - 搜索广告top query上初步实验CTR ↑ 2.7%, 下侧热卖宝贝 CTR ↑ 4.6%(仍需优化以得到最佳效果。对比线上ctr ↑ 10%)



- PLSA:

$$y(u, i) = \sum_{k=1}^K \Phi_{u,k} \Psi_{i,k}$$

- MLR模型

$$f(x) = \sum_{k=1}^K \pi_k(x) \eta_k(x)$$

- 如果以user id 和item id作为特征：

$$y(u, i) = \sum_{k=1}^K \pi_k(u, i) \eta_k(u, i)$$

- 限制 $\pi$ 中 $i$ 权重为0， $\eta$ 中 $u$ 权重为0，则完全等价于PLSA，参数一一对应

- **MLR更灵活**：参数更多

- PLSA是二次模型。
    - MLR用分片线性思想，有拟合任意阶次函数能力

- **MLR很容易引入其它特征**，提高精度，解决冷启动问题



# 带偏移变量的MLR

- 问题：宝贝展示的页面、位置影响点击概率
- 宝贝特征 $x$ ，偏移向量 $y$ (场景、页数、位置等)：
  - 学习联合概率 $p(x,y)$  — 需要 $x,y$ 的大部分组合
  - 采样问题：并不是 $x,y$ 的所有组合能采到样本
- **提出带偏移MLR算法**： $p(x,y|\theta,w) = p_{mlr}(x|\theta)p_{lr}(y|w)$ 
  - $y$ :偏移向量，包括场景、页数、位置等信息
  - 只需很少一些 $x,y$ 组合
  - AUC指标  $\uparrow$  2-8%
- 应用：精品库场景CTR  $\uparrow$  30+%

大规模非线性ctr/cvr预估和偏移变量的分解一起优化



# Transfer MLR

- 问题：淘客搜索场景cvr预估中购买样本过少
- 思路：借鉴主搜购买数据做样本
  - 难点：样本有偏：主搜场景购买率明显高于淘客搜索

## Transfer MLR：

- 去除不同规律，借鉴相同规律 传递宝贝的吸引力:mlr参数相近
- 设宝贝特征 $x$ ，淘客偏移向量 $y$ ，主搜偏移向量 $z$  ( $y, z$ 不同维度)

- 淘客搜索： $pcvr_t(x, y) = p_{mlr}(x; \theta_t) p_{lr}(y; w_t)$
- 主搜： $pcvr_s(x, z) = p_{mlr}(x; \theta_s) p_{lr}(z; w_s)$
- 损失： $L_t(pcvr_t(x, y|\theta_t, w_t)) + \lambda L_s(pcvr_s(x, z|\theta_s, w_s)) + \gamma \|\theta_s, \theta_t\|_{2,1}$  s.t.  $\|\theta_s - \theta_t\| \leq \beta$
- $\beta \rightarrow 0$ 时  $L_t(pcvr_t(x, y|\theta, w_t)) + L_s(pcvr_s(x, z|\theta, w_s)) + r(\theta, w_s, w_t)$

吸收不同场景的不同

- 应用效果：淘客宝贝排序pcvr  $\uparrow$  30+%

淘宝网  
Taobao.com

THANK YOU

